

CONCURSO HOLA MUNDO 2026

Primer Concurso de Innovación en Tecnología de Seguridad

REPORTE DE PRUEBAS DE CARGA Y ESTRÉS

Proyecto: Shogun AI v2.6

Categoría: A - Reconocimiento Facial

Equipo: Shogun Eye

Integrantes: Daniel Santoyo Arévalo

Fecha: 03 de Junio de 2026

1. Entorno de Pruebas y Condiciones Base

Las presentes pruebas de carga y saturación fueron ejecutadas *on-premise* en un entorno local aislado. El objetivo de este aislamiento es evaluar el rendimiento puro del motor asíncrono Multithreading y los tiempos de inferencia matemática neuronal, eliminando cualquier latencia externa provocada por la nube o servicios de terceros.

1.1 Hardware del Servidor de Pruebas (Host)

- **Procesador (CPU):** Intel(R) Core(TM) i5-1035G1 CPU @ 1.00GHz.
- **Memoria RAM:** 16 GB totales.
- **Almacenamiento:** SSD NVMe Kingston de 500GB (garantiza alta velocidad de lectura/escritura para los logs de acceso y bóveda local de evidencias).
- **Aceleración Gráfica (GPU):** Intel UHD Graphics integrada (sin aceleración nativa CUDA/cuDNN; el sistema fue sometido a estrés operando 100% sobre procesamiento de CPU).
- **Sistema Operativo:** Windows 11.
- **Red de Captura:** Red Wi-Fi local operando mediante protocolo IP (DroidCam Client) para streaming continuo de frames.

1.2 Población de Datos (Vector Database)

- **Motor de Búsqueda:** Meta FAISS (algoritmo de búsqueda logarítmica para Distancia Euclidiana).
- **Volumen de Nodos:** 10,006 registros biométricos (vectores a 128 dimensiones) precargados y mantenidos activamente en la memoria RAM.

2. Escenario Base: Carga Nominal (Consulta Única)

Objetivo: Medir la estabilidad y el rendimiento del sistema al procesar un único individuo frente a la cámara IP, verificando que la delegación asíncrona no degrade el flujo visual de 30 FPS de la interfaz.

Metodología: Exposición continua de un rostro válido a 50 centímetros del lente durante 60 segundos ininterrumpidos. El sistema activa simultáneamente el motor Anti-Spoofing (extracción de Eye Aspect Ratio vía MediaPipe) y la inferencia convolucional (FaceNet).

Resultados Medidos:

- **Consumo promedio de CPU:** Estable en 66%.
- **Consumo de RAM del proceso:** Fluctuación controlada entre 0.5 GB y 0.55 GB (atribuible principalmente a los pesos neuronales de DeepFace).
- **Latencia p95:** 550 milisegundos desde la captura inicial del rostro hasta la resolución de coincidencia en la base de datos de 10,006 registros.
- **Throughput:** 1 ciclo de evaluación biométrica profunda por frame validado, sin generar embotellamientos en el hilo principal de renderizado (Tkinter/OpenCV).

3. Escenario Sostenido: Modo Vigilancia (Multitarget)

Objetivo: Evaluar la capacidad del sistema para procesar múltiples rostros simultáneos (conurrencia) durante un periodo prolongado, sin degradar el rendimiento general del host.

Metodología: Captura de video con presencia de múltiples individuos en el campo de visión de la cámara durante 5 minutos continuos. El sistema ejecuta hilos secundarios (Multithreading) de manera paralela para cada rostro detectado para no bloquear el flujo de video.

Resultados Medidos:

- **Consumo promedio de CPU:** 75% (Aumento esperado por el manejo concurrente de la carga multihilo).
- **Consumo de RAM del proceso:** ~0.60 GB estables.
- **Latencia p95:** 600 milisegundos para la extracción neuronal y validación de cada rostro.
- **Throughput:** Detección y rastreo multitarget sostenido a 30 FPS. El hilo principal (interfaz y streaming) no presentó bloqueos ni cuelgues.

4. Escenario de Pico: Ráfaga de Consultas Concurrentes

Objetivo: Determinar el comportamiento del motor asíncrono ante la aparición repentina de múltiples rostros (ráfaga) en un solo frame o cuadro de video.

Metodología: Inyección de un entorno visual complejo con múltiples rostros simultáneos, forzando al sistema a invocar paralelamente varias inferencias de FaceNet y consultas simultáneas de rechazo o acceso hacia la base de datos Meta FAISS.

Resultados Medidos:

- **Comportamiento de Hilos:** El core asíncrono encoló y delegó las peticiones exitosamente.

- **Tiempo de Recuperación:** El sistema resolvió todas las inferencias concurrentes manteniendo la latencia normativa por debajo de los límites exigidos.
- **Impacto Visual:** Cero pérdida de frames en el renderizado de OpenCV; la interfaz gráfica se mantuvo perfectamente fluida a 30 FPS, demostrando un aislamiento arquitectónico perfecto entre la lógica pesada y la interfaz de usuario.

5. Escenario Adverso: Estrés Vectorial Masivo

Objetivo: Comprobar el impacto en la latencia de búsqueda cuando el tamaño de la base de datos iguala y supera el límite mínimo exigido por la categoría (10,000 registros).

Metodología: Ejecución de búsquedas logarítmicas de validación (distancia euclidiana) contra el índice en memoria RAM de FAISS, poblado activamente con 10,006 nodos vectoriales (mezcla de datos reales e inyección sintética de estrés).

Resultados Medidos:

- **Latencia de Búsqueda (FAISS puro):** p95 de 15 milisegundos.
- **Precisión de Retención:** Éxito absoluto en la identificación (Distancia Euclidiana < 10.0) y en el rechazo correcto de los vectores no autorizados.
- **Consumo de RAM Adicional:** El impacto de mantener el clúster de los 10,006 vectores en la memoria del host fue altamente eficiente y espacialmente nulo frente a la capacidad de 16 GB totales.

6. Análisis de Saturación y Límites Operativos

Definición de Saturación: El punto donde la latencia p95 de respuesta iterativa supere el límite normativo de la categoría (1.0 segundos) o donde el hilo principal reduzca los FPS drásticamente haciendo el sistema inoperable.

Conclusión del Límite del Sistema: Bajo las pruebas de carga locales ejecutadas en el hardware documentado, el sistema no alcanzó su punto de saturación de CPU. El límite teórico de operación radica en la memoria RAM del host (16 GB), el cual, operando de manera estable en un máximo de 0.6 GB durante el escenario sostenido, otorga un margen de escalabilidad operativo masivo para entornos corporativos reales.

Se concluye que el sistema mantendrá su respuesta inferior a 1 segundo gracias a su delegación asíncrona y a la eficiencia de los vectores matemáticos de FAISS, superando satisfactoriamente los requisitos del nivel empresarial.